


Arabic lexicon: what is missing from the Qur'an and hadith, and why

Isharati EDA, 2026-10-05. Lexicon: *Lexicon_qa.jsonL* (6,632 signs, 6,602 distinct glosses). Corpus: Qur'an + hadith, 595,022 content-word occurrences (stopwords excluded).

Bottom line

The headline **57.4 %** is *not* "57 % of our glosses". It is the share of **every content-word occurrence in the Qur'an and hadith** that the matcher links to a sign. Only **4.8%** of those occurrences are words we truly have no sign for. Most of the uncovered 42.6 % are words **we already sign**, written in a form the matcher does not recognise:

Why a word is counted as uncovered	Share of all content words	Examples
Verb form, and its lemma has a sign (يقول → قال)	12.3%	وسلم (12,493)، قالت (842)، يكون (813)، قالوا (646)، وجل (570)، كانوا (554)، قلت (486)، كنت (477)
Noun/adjective form, and its lemma has a sign	4.1%	بن (3,936)، شيء (1,071)، مثل (607)، انما (488)، ربك (337)، يده (293)، يديه (261)، بيده (249)
Function word missing from the stopword list	6.5%	عنه (3,746)، الا (3,728)، ولا (3,389)، به (2,443)، انه (2,154)، منه (1,259)، فلا (1,069)، عنهما (951)
Proper name (fingerspell, or a name sign)	3.8%	شيبيا (682)، عباس (495)، المومنين (391)، عمرو (288)، مسعود (265)، جبريل (258)، زيد (199)، المومن (184)
Same root as a sign, different word (needs review)	11.3%	هريره (890)، قبل (846)، بكر (663)، عز (569)، روايه (419)، قوله (405)، الصحابه (395)، دون (338)
Truly missing: verb	1.9%	اخذ (245)، حصل (112)، فاخذ (107)، ينبغي (100)، يحصل (97)، عروه (88)، افلا (84)، ياخذ (71)
Truly missing: noun/adjective	2.9%	الدنيا (730)، سبيل (420)، عذاب (268)، الابل (158)، العذاب (144)، شيت (140)، حاجه (94)، الدجال (88)



Why this happens

1. **Verbs are matched only in their exact form.** The matcher deliberately refuses to lemmatise anything that can be read as a verb (a guard so that «وتكفر», *expiates*, cannot become «كفر», *disbelief*). As a result «قلت، قالوا، قالت، يقول» all miss the sign «قال»، even though in ArSL the person and tense are not separate signs: «يقول» is signed as قال, with هو only when needed.
2. **Noun forms with clitics or other inflections are missed:** «ربك، ربنا، ربه» (our sign: رب), «يد، يديه، بيده» (يد).
3. **The stopword list has 60 words**, so function words such as «عنه، إلا، ولا، به، أنه، منه، فلا، إليه» count as uncovered content words, which inflates the denominator.
4. **Phrases:** «وسلم» and «وجل» come from the fixed formulas «صلى الله عليه وسلم» and «عز وجل»، which should be phrase signs.

What fixing it is worth

Change	Coverage
Now	57.4%
+ lemma matching for verbs and nouns whose lemma has a sign	73.7%
+ function words moved to the stopword list	78.8%
+ proper names fingerspelled	82.8%

The "same root" group (11.3%) is **not** counted, because a shared root does not mean a shared meaning (قبل *before* vs قِيل *accepted*; عز). It needs review word by word.

The verb fix keeps a meaning guard: a verb form maps to a sign only when the sign's gloss is **itself that verb** (same CAMEL lemma, verb reading). So «قال → يقول» is allowed, but a noun sign never absorbs an unrelated verb.

The words to record next (truly missing, by lemma frequency)

#	Lemma	Occurrences	Forms seen
1	اخذ	1,260	اخذ، فاحذ، ياخذ، اخذه، فخذ، اخذت
2	دنيا	797	الدنيا، والدنيا، دنياه، دنيا، للدنيا، بالدنيا
3	عذاب	610	عذاب، العذاب، عذابا، بعذاب، عذابي، وعذاب
4	سبيل	556	سبيل، السبيل، سبيلا، سبيله، السيل، سبيلي
5	ظن	346	ظن، الظن، يظن، اظن، ظنا، ظنه
6	حاجه	333	حاجه، حاجته، الحاجه، لحاجه، لحاجته، حاجتها
7	صوت	322	صوته، صوت، الصوت، صوتا، بصوت، صوتك
8	حصل	309	حصل، يحصل، تحصل، وحصل، حصلت، فحصل
9	لعل	250	لعلكم، لعلهم، لعله، لعل، ولعل، فلهله
10	أُتخذ	238	اتخذ، اتخذوا، يتخذ، تتخذوا، اتخذها، واتخذوا
11	كفي	233	وكفي، كفي، يكفي، يكفيك، يكفيه، ويكفي
12	ابل	224	الابل، ابل، ابله، ابلي، والابل، ابلا
13	نفع	222	ينفع، نفعاً، ينفعه، نفعه، نفع، النفع
14	خشي	218	خشيه، يخشي، خشيت، خشي، اخشي، يخشون
15	غلام	196	الغلام، غلام، غلاما، بغلام، غلامه، غلامك
16	اثم	189	اثم، الاثم، اثما، اثمه، والاثم، بالاثم
17	ادرك	189	ادرك، يدرك، ادركه، يدركه، ادركت، فادركته
18	قبض	171	قبض، قبضه، يقبض، يقبضه، فيقبض، فتقبض
19	غنم	169	الغنم، غنم، والغنم، غنما، غنمه، غنمتم
20	لفظ	155	لفظ، اللفظ، بلفظ، ولفظ، الفاظ، لفظه
21	كف	153	كفه، كف، كفيه، وكف، الكف، فكف
22	أُنْبِغِي	142	ينبغي، فينبغي، وينبغي
23	عذب	141	يعذب، عذب، يعذبون، يعذبهم، ويعذب، عذبه
24	شيت	140	شيت
25	زمان	139	الزمان، زمان، زمانا، زمانه، الزمان
26	بعير	133	بعير، بعيرا، البعير، بعيره، ببعير، ببعيرها
27	وتر	129	الوتر، يوتر، وترا، والوتر، فليوتر، بالوتر
28	لبن	128	اللبن، باللبن، لبنه، واللبن، بلبن، لبنها
29	منبر	121	المنبر، منابر، منبر، منبره، ومنبري، منبرا
30	عري	115	عروه، عريانا، عري، لعروه، عرينه، العريه
31	وراء	110	وراء، وراءه، وراءهم، وراءها، وراءك، وراءكم
32	مضي	104	مضي، ومضي، مضت، فمضي، يمضي، المضي
33	زمن	104	زمن، الزمن، زمنا، وزمن، زمنه، كالزمن
34	أُحتاج	104	يحتاج، احتاج، احتجت، يحتاجون، تحتاج، ويحتاج
35	اعتق	104	اعتق، اعتقها، يعتق، يعتقه، فاعتقها، اعتقت

#	Lemma	Occurrences	Forms seen
36	عنق	102	عنقه، اعناقهم، عنقها، عنق، اعناق، العنق
37	جيش	102	الجيش، جيش، جيشا، الجيوش، بالجيش، جيوش
38	حرب	101	الحرب، حرب، الحروب، للحرب، بالحرب، بحرب
39	بدن	101	بدنه، البدن، بالابدان، والبدن، بدنك، بدن
40	اوصي	99	اوصي، يوصي، اوصيكم، اوصاه، فاوصي، يوصيكم
41	ورث	97	يرث، ورثه، يورث، يرثون، يورثوا، ترثوا
42	دفن	96	دفن، دفنه، يدفن، تدفن، ودفن، الدفن
43	دجال	95	الدجال، والدجال، دجال، بالدجال، دجالون، للدجال
44	بغى	93	بغته، البغي، بغى، بغيا، يبغون، والبغى
45	نزع	91	نزع، ينزع، تنزع، نزع، فنزعت، فنزعه
46	فات	91	فاتني، فاته، يفتن، يفوت، فاتكم، فاتنا
47	قتاد	90	قتاده، لقتاده
48	أبتغي	88	يبتغون، يبتغي، تبتغي، تبتغوا، ابتغي، ابتغيت
49	عضو	86	اعضاء، الاعضاء، عضوا، عضو، العضو، اعضاءه
50	حبس	86	حبس، حبست، حبسني، يحبس، احبس، تحبس
51	فم	86	فمه، فم، الفم، للفم، فمها، بفمه
52	افل	85	افلا، الافلين
53	معاويه	85	معاويه، لمعاويه، ومعاويه
54	ابصر	84	ابصر، يبصرون، يبصر، تبصرون، ابصرنا، ابصرت
55	كاد	84	كاد، يكاد، كادوا، تكاد، كادت، اكاد
56	لعنه	84	لعنه، اللعان، اللعنه، بلعنه، لعانا، باللعان
57	دام	82	دام، دامت، دمت، داموا، تدوم، يدمنها
58	نعل	82	نعالهم، نعلين، النعل، النعلين، النعال، بنعلي
59	صاع	76	صاعا، صاع، بصاع، بالصاع، صاعين، الصاع
60	بصير	75	بصير، بصيرا، البصير، والبصير
61	حث	75	حث، يحث، وحث، تحثي، ويحث، وحثهم
62	زار	73	تزورنا، زار، تزر، يزور، يزوره، ازور
63	جهر	71	الجهر، تجهر، جهرا، يجهرون، جهر، جهرنا
64	فقه	71	يفقهون، فقه، فقهوا، وفقه، الفقه، يفقهوا
65	نخل	69	النخل، النخيل، نخلا، والنخل، والنخيل، بنخل
66	ابصار	65	ابصارهم، الابصار، والابصار، وابصارهم، وابصارنا، بابصارهم
67	أفتري	64	يفترون، افتري، افتراه، يفترى، يفتر، تفترون
68	لعن	61	اللعن، العن، لعنهم، العنك، وتلعنونه، ويلعنونكم
69	بول	61	البول، يبول، بوله، وبوله، وابوالها، والبول
70	ذمه	60	ذمه، وذمه، ذمته، ذمته، الذمه، ذمته

#	Lemma	Occurrences	Forms seen
71	نافع	60	نافع، نافعاً، النافع، نافعه، النافعه، وبنافع
72	مرء	59	المرء، بالمرء، والمرء
73	انكح	59	ينكح، تنكح، ينكحها، فانكحوا، وانكحوا، انكحتك
74	عزا	59	وعزتك، اعز، عزا، اعزه، يعز، وتعز
75	حرج	59	حرج، الحرج، حرجا، وحرج، والحرج
76	شكا	58	شكوا، يشك، يشكون، يشكو، تشكو، فشكوا
77	كتف	58	كتفيه، الكتف، كتفه، كتفي، كتفها، كتف
78	كنم	57	يكنمون، كنم، تكنمون، يكتم، فكنمه، وتكنمون
79	وصيه	57	الوصيه، وصيه، ووصيته، بوصيه، وصيته، وصيتي
80	رجم	57	الرجم، رجم، فرجمت، بالرجم، فرجمناه، فرجما

The full lists (500 lemmas; top 150 words per category) are in `categories.json` next to this report.

Method

- The corpus is tokenised and normalised exactly as `scripts/eval/corpus_eda.py` does. The matcher is the app's own (`qa_lexicon(...).match_token`). Stopwords are `arabic_morph.STOPWORDS`.
- Every uncovered word type is analysed with CAMEL Tools (`calima-msa` built-in database, NOAN_PROP back-off). The top-scoring analysis gives the POS, lemma and root. Glosses are analysed the same way.
- Categories are applied in order: no analysis → function-word POS → proper noun → lemma equals a gloss or a gloss's lemma (verb / noun) → shared root → truly missing.
- **Limits:** the top analysis is context-free, so ambiguous words can land in the wrong bucket. The projections assume the lemma fix is precise. A precision check on a sample comes with the fix itself.